IMT Atlantique
Technopôle de Brest-Iroise - CS 83818
29238 Brest Cedex 3
URL : **www.imt-atlantique.fr**

Calibration profonde interprétable de modèles de volatilité rugueuse

Rendu 1 : cadrage du projet

Khalil Errahmène Dahmeni
Mohamed Youssef Cherif
Amaury Janin
Amro Benramdane
Anthony Der Kevorkian
Souha Boukadida

Date d'édition : 16 octobre 2026
Encadrant : Jean-Marc Le Caillec

IMT Atlantique
Bretagne-Pays de la Loire
École Mines-Télécom

Sommaire

1. Contexte et problématique 2
1.1. Pourquoi un modèle de volatilité rugueuse 2
1.2. Le verrou : le coût de la calibration 2
1.3. Problématique 3

2. L'article de référence 3
2.1. Le modèle 3
2.2. Dispositif de l'article 4

3. Limites de l'article et pistes 4

4. Plan d'action 4
4.1. Chaîne de traitement 4
4.2. Comparer les architectures 5
4.3. Organisation 5

5. Réseaux de neurones pour la calibration 5
5.1. Deux façons d'utiliser un réseau 5
5.2. Les architectures possibles 6

6. À quoi sert le projet 6
6.1. Calibrer pour valoriser et couvrir 6
6.2. La couverture 6
6.3. L'apport des réseaux pour la couverture 7
6.4. Les autres usages 7
6.5. Le problème de la boîte noire 7

7. Données et livrables 7
7.1. Données 7
7.2. Livrables 7

1. Contexte et problématique

1.1. Pourquoi un modèle de volatilité rugueuse

Le modèle de Black–Scholes suppose que la volatilité est constante. Si c'était le cas, la volatilité implicite serait la même pour tous les strikes et toutes les maturités, et la surface de volatilité serait plate. Ce n'est pas ce qu'on observe : sur les indices actions, la volatilité implicite est plus élevée pour les strikes bas (c'est le *skew*), et cette pente dépend de la maturité.

Les modèles à volatilité stochastique, comme celui de Heston, reproduisent bien ces formes pour les maturités moyennes et longues. Ils ont en revanche du mal sur les maturités courtes : quand la maturité T tend vers zéro, la pente du smile à la monnaie, notée $\psi(T)$, reste bornée dans le modèle de Heston, alors qu'elle devient très forte sur le marché.

Les modèles de volatilité rugueuse corrigent ce défaut en pilotant la variance par un processus fractionnaire, beaucoup plus irrégulier qu'un mouvement brownien, dont l'irrégularité est mesurée par l'indice de Hurst H. La pente se comporte alors comme

$$\psi(T) \;\sim\; C \cdot T^{H-\frac{1}{2}} \qquad (T \to 0). \tag{1}$$

Sur les marchés actions, on estime $H \approx 0{,}1$, ce qui donne une pente qui explose en $T^{-0,4}$, proche de ce qu'on observe. Pour $H = 1/2$, on retrouve le comportement de Heston. C'est pour cela que nous travaillons avec cette famille de modèles.

1.2. Le verrou : le coût de la calibration

Calibrer un modèle, c'est chercher les paramètres Θ qui reproduisent le mieux la surface observée sur une grille de N strikes et M maturités :

$$\Theta^* = \arg\min_{\Theta} \sum_{i=1}^{N} \sum_{j=1}^{M} w_{i,j} \left(\sigma_{\text{imp}}^{\text{mod}}(K_i, T_j; \Theta) - \sigma_{\text{imp}}^{\text{mkt}}(K_i, T_j) \right)^2 . \tag{2}$$

Chaque essai de l'optimiseur demande de recalculer toute la surface. Or, dans un modèle rugueux, la variance dépend de toute sa trajectoire passée et il n'existe pas de formule fermée : il faut résoudre numériquement une équation de Riccati fractionnaire, ou passer par du Monte Carlo. Comme l'optimiseur fait plusieurs centaines d'essais, une calibration peut prendre plusieurs minutes, ce qui est trop lent pour un desk qui recalibre plusieurs fois par jour.

L'idée de la calibration profonde (*deep calibration*) est de déplacer ce coût : on entraîne une fois un réseau de neurones sur des surfaces simulées, et il répond ensuite en quelques millisecondes.

1.3. Problématique

Nous partons de la démarche de l'article de référence : apprendre la calibration du rough Heston avec un réseau de neurones, puis chercher à comprendre ce que le réseau a appris. Nous souhaitons l'étendre dans deux directions.

Le choix du réseau. L'article n'utilise qu'un réseau dense (*feedforward*). Il nous semble intéressant d'essayer d'autres architectures sur la même tâche, par exemple un CNN, puisque la surface est une grille, ou un LSTM, en lisant l'axe des maturités comme une séquence. L'interprétabilité pourrait alors aider à les comparer : à précision proche, on peut préférer un réseau qui s'appuie sur les zones de la surface où la théorie attend l'information.

La couverture. Un modèle calibré sert d'abord à couvrir un portefeuille d'options. Deux jeux de paramètres peuvent donner des surfaces très proches mais des couvertures différentes, car une couverture dépend des dérivées du prix et pas seulement de son niveau. Nous voudrions donc regarder si une calibration par réseau permet de bien couvrir, et pas seulement de bien reproduire les prix.

Notre question de départ est donc la suivante : **une calibration rapide par réseau de neurones permet-elle de couvrir correctement un portefeuille d'options, et l'interprétabilité peut-elle aider à choisir le réseau ?**

2. L'article de référence

B. Yuan, D. Brigo, A. Jacquier, N. Pede, *Deep Learning Interpretability for Rough Volatility*, arXiv :2411.19317, novembre 2024.

L'article entraîne un réseau qui lit une surface de volatilité et renvoie les paramètres du modèle rough Heston, puis utilise plusieurs méthodes d'interprétabilité pour voir sur quelles parties de la surface le réseau s'appuie.

2.1. Le modèle

Sous la probabilité risque-neutre, en négligeant taux et dividendes, $\mathrm{d}S_t/S_t = \sqrt{V_t}\,\mathrm{d}B_t$, et la variance s'écrit

$$V_t = V_0 + \frac{\kappa}{\Gamma\left(H+\frac{1}{2}\right)} \int_0^t (t-s)^{H-\frac{1}{2}} \Big[(\theta - V_s)\,\mathrm{d}s + \nu\sqrt{V_s}\,\mathrm{d}W_s \Big], \tag{3}$$

avec $\mathrm{d}\langle B, W\rangle_t = \rho\,\mathrm{d}t$. Le terme $(t-s)^{H-1/2}$ donne du poids à tout le passé de la variance : le processus n'est plus markovien, et c'est ce qui rend les calculs coûteux. Pour $H = 1/2$, on retrouve le modèle de Heston.

V_0	variance initiale	ν	intensité des fluctuations de variance
θ	variance de long terme	ρ	corrélation prix / variance
κ	vitesse de retour à la moyenne	H	rugosité

2.2. Dispositif de l'article

Grille	9 strikes $\{0{,}6 \dots 1{,}4\}$ (en proportion du prix) $\times$ 6 maturités de 0,6 à 2 ans, soit 54 points
Données	10 000 jeux de paramètres simulés, avec trois plages de valeurs
Réseau	réseau dense à une couche cachée, 54 entrées, 6 sorties
Interprétabilité	LIME, DeepLIFT, LRP, SHAP

Les auteurs observent que certaines zones de la surface comptent beaucoup plus que d'autres, mais que les méthodes ne donnent pas toujours la même réponse, et que certains paramètres, comme κ, restent difficiles à retrouver.

3. Limites de l'article et pistes

Plusieurs points de l'article nous paraissent pouvoir être approfondis :

1. **Une seule architecture** est testée : d'où l'idée de comparer plusieurs réseaux.
2. **L'étude s'arrête à la calibration** : la couverture, qui est l'usage final du modèle, n'est pas étudiée.
3. **Les méthodes d'interprétabilité ne sont pas toujours d'accord**, et il n'y a pas de référence pour savoir laquelle croire. Les sensibilités de la surface aux paramètres, calculées directement sur le modèle, pourraient servir de point de comparaison.
4. **Certains paramètres sont difficiles à identifier** : plusieurs jeux de paramètres peuvent donner presque la même surface. Il serait utile de mesurer ce phénomène plutôt que de seulement le constater.
5. **Les surfaces utilisées sont parfaites** : sans bruit et complètes, alors qu'un marché réel ne cote pas tous les points et que les prix sont bruités.
6. **Les maturités courtes sont absentes** de la grille (au moins 0,6 an), alors que c'est là que la rugosité se voit le plus.

4. Plan d'action

4.1. Chaîne de traitement

1. **Simuler** des surfaces rough Heston pour constituer le jeu d'apprentissage.

2. **Apprendre** le pricer par réseau, en deux étapes, et vérifier sa précision par rapport au pricer de référence.
3. **Calibrer** sur une surface donnée : synthétique, puis bruitée ou partiellement observée.
4. **Calculer les sensibilités** par différentiation automatique et les contrôler.
5. **Évaluer la couverture** en simulant le résultat d'une couverture en delta sur des trajectoires, et en comparant le rough Heston calibré par réseau, le rough Heston calibré par optimisation classique, et Black–Scholes. On pourra aussi regarder l'effet d'une erreur de calibration sur la qualité de la couverture.
6. **Interpréter** les décisions du réseau, par exemple avec SHAP, pour voir quelles zones de la surface il utilise.

Selon l'avancement, les étapes 2 à 6 pourront être reprises avec d'autres architectures.

4.2. Comparer les architectures

Pour que la comparaison ait un sens, l'idée serait d'entraîner les réseaux sur les mêmes données, avec les mêmes seeds et des tailles comparables. Plusieurs critères peuvent être regardés : la précision sur les paramètres, la qualité de la surface reconstruite, la qualité de la couverture, la robustesse au bruit, la cohérence des zones utilisées avec ce qu'on attend du modèle, et le temps de calcul. Nous choisirons les critères les plus pertinents au fur et à mesure du projet.

4.3. Organisation

Une piste pour avancer prudemment est de commencer par le modèle de Heston classique, beaucoup plus rapide à calculer, pour mettre en place toute la chaîne avant de passer au modèle rugueux. Cette version servirait aussi de point de comparaison, puisque $H = 1/2$ y est connu.

5. Réseaux de neurones pour la calibration

5.1. Deux façons d'utiliser un réseau

Un réseau de neurones peut remplacer l'étape lente de la calibration de deux manières :

- **calibration directe** : le réseau lit une surface de volatilité implicite et renvoie directement les paramètres du modèle. C'est l'approche de Yuan et al. [1]. Elle est très rapide, mais peut être ambiguë si deux jeux de paramètres donnent presque la même surface ;
- **calibration en deux étapes** : le réseau apprend d'abord le pricer (paramètres → surface), puis un optimiseur classique cherche les paramètres en utilisant ce réseau à

la place du pricer. C'est l'approche de Horvath et al. [3]. Elle reste rapide et donne en plus les dérivées du prix par rapport aux paramètres, utiles pour la couverture.

Dans les deux cas, le réseau est entraîné une fois pour toutes sur des surfaces simulées avec le modèle ; le coût de calcul est payé avant, et non au moment de calibrer.

5.2. Les architectures possibles

Réseau	**Adapté à**	**Pour notre projet**
Réseau dense (FNN)	des vecteurs de taille fixe	une surface est une petite grille de nombres : c'est le choix des trois articles de référence
Réseau convolutif (CNN)	des données avec une structure locale (images, signaux)	surface comme une image, ou CNN comme MLP
Réseau récurrent (LSTM)	des séquences ordonnées (séries temporelles)	l'axe des maturités de la surface peut être lu comme une séquence

Le PROCOM 2024–2025 a utilisé un CNN et un LSTM pour estimer la rugosité H directement sur des trajectoires simulées. Notre projet part d'une autre entrée, la surface de volatilité implicite, à partir de laquelle nous chercherons à retrouver, dans la mesure du possible, l'ensemble des paramètres du modèle. Nous partirons des architectures utilisées dans les articles de référence et de celles déjà testées par le PROCOM précédent, et nous pourrons éventuellement tester d'autres modèles de prédiction. Des pistes pour les comparer sont données en section 4.

6. À quoi sert le projet

6.1. Calibrer pour valoriser et couvrir

Une banque qui vend des options utilise un modèle de volatilité pour deux choses : donner un prix cohérent avec les options cotées sur le marché (pricing), et se protéger contre les variations de ce prix (couverture, ou hedging). Le modèle doit être recalibré souvent, au moins chaque jour, sur la surface observée. Pour les modèles rugueux, chaque calibration classique est lente ; un réseau de neurones permet de la faire en quelques millisecondes.

6.2. La couverture

Couvrir une option, c'est prendre une position inverse dans d'autres actifs pour que les gains et les pertes se compensent. Dans le modèle de Black–Scholes, il suffit de détenir une quantité $\Delta = \partial P/\partial S$ de sous-jacent (le delta), réajustée régulièrement. Dans un modèle à volatilité stochastique comme le rough Heston, la volatilité est elle-même aléatoire et ne s'échange pas directement : le sous-jacent ne suffit plus. Il faut aussi couvrir la sensibilité à la volatilité (le vega), avec d'autres options. El Euch et Rosenbaum [4] montrent que,

dans le rough Heston, une couverture parfaite est possible en théorie avec le sous-jacent et des produits sur la variance future. Sur un indice, la volatilité monte quand le marché baisse : un modèle bien calibré donne donc un delta différent de celui de Black–Scholes, et plus juste.

6.3. L'apport des réseaux pour la couverture

Couvrir demande les sensibilités du prix (les *Greeks*). Avec un réseau qui remplace le pricer, ces dérivées s'obtiennent directement par différentiation automatique, alors qu'une méthode classique doit répéter de nombreux calculs de prix. Il faudra vérifier que ces dérivées sont fiables, en les comparant à celles du pricer de référence.

6.4. Les autres usages

Un modèle bien calibré sert aussi à valoriser des produits peu liquides à partir des options cotées (options à barrière, produits structurés), et à mesurer les risques d'un portefeuille, ce qui demande de le réévaluer un très grand nombre de fois. Dans les deux cas, la vitesse du réseau est un avantage direct.

6.5. Le problème de la boîte noire

Une banque ne peut pas utiliser un modèle qu'elle ne sait pas expliquer : un réseau de neurones donne des paramètres sans dire pourquoi. Des méthodes d'interprétabilité sont en cours de développement pour répondre à cette question, notamment les valeurs de Shapley (SHAP), utilisées par Yuan et al. [1] : elles indiquent quels points de la surface (quels strikes et quelles maturités) le réseau utilise pour estimer chaque paramètre. Pour la couverture, cette information pourrait aussi indiquer quelles options utiliser pour couvrir chaque risque.

7. Données et livrables

7.1. Données

La chaîne de traitement décrite en section 4 sera d'abord appliquée à des surfaces simulées, puis à des données de marché réelles. Nous disposons en effet des options sur l'indice S&P 500 de la base OptionMetrics (accès WRDS), de 1996 à 2025. Elles permettront de tester la calibration sur de vraies surfaces et de la comparer à une calibration classique. Le modèle rough Bergomi pourra être étudié en extension si le temps le permet.

7.2. Livrables

Un code Python documenté (simulation, réseaux, couverture, interprétabilité), un jeu de données synthétique reproductible, un rapport final et un poster.

Références

[1] B. Yuan, D. Brigo, A. Jacquier, N. Pede. Deep Learning Interpretability for Rough Volatility. arXiv :2411.19317, 2024.

[2] F. Biagini, L. Gonon, N. Walter. Approximation Rates for Deep Calibration of (Rough) Stochastic Volatility Models. *SIAM Journal on Financial Mathematics*, 2024.

[3] B. Horvath, A. Muguruza, M. Tomas. Deep learning volatility. *Quantitative Finance*, 2021.

[4] O. El Euch, M. Rosenbaum. Perfect hedging in rough Heston models. *The Annals of Applied Probability*, 2018.

OUR WORLDWIDE PARTNERS UNIVERSITIES - DOUBLE DEGREE AGREEMENTS



3 CAMPUS, 1 SITE



IMT Atlantique Bretagne–Pays de la Loire – **http://www.imt-atlantique.fr/**

Campus de Brest
Technopôle Brest-Iroise
CS 83818
29238 Brest Cedex 3
France
T +33 (0)2 29 00 11 11
F +33 (0)2 29 00 10 00

Campus de Nantes
4, rue Alfred Kastler
CS 20722
44307 Nantes Cedex 3
France
T +33 (0)2 51 85 81 00
F +33 (0)2 99 12 70 08

Campus de Rennes
2, rue de la Châtaigneraie
CS 17607
35576 Cesson Sévigné Cedex
France
T +33 (0)2 99 12 70 00
F +33 (0)2 51 85 81 99

Site de Toulouse
10, avenue Édouard Belin
BP 44004
31028 Toulouse Cedex 04
France
T +33 (0)5 61 33 83 65

IMT Atlantique
Bretagne-Pays de la Loire
École Mines-Télécom

© IMT Atlantique, 2026

Imprimé à IMT Atlantique
Dépôt légal : Octobre 2026
ISSN : n° ISSN